

Regresja liniowa




Rozkład jazdy

- Po co nam regresja liniowa?
- Funkcja, funkcja liniowa
- Regresja liniowa – definicja
- Własna implementacja
- Ćwiczenia z wykorzystaniem
sklearn







Regresja liniowa – wzrost społeczeństwa






Regresja liniowa – wzrost społeczeństwa





Regresja liniowa – wzrost społeczeństwa





Czym jest funkcja?


$$y = f(x)$$





CECHY


**KOSMICZNE I
NIEPRAWDOPODOBNE
OBLICZENIA**














X – wejście funkcji, zmienna objaśniająca, niezależna
 Y – odpowiedź funkcji, zmienna objaśniana, zależna
 a – współczynnik ,slope', kierunkowy
 b – współczynnik ,intercept', przesunięcie


$$y=a*x+b$$

X – wejście funkcji, zmienna objaśniająca, niezależna

Y – odpowiedź funkcji, zmienna objaśniana, zależna

a – współczynnik ,slope', kierunkowy

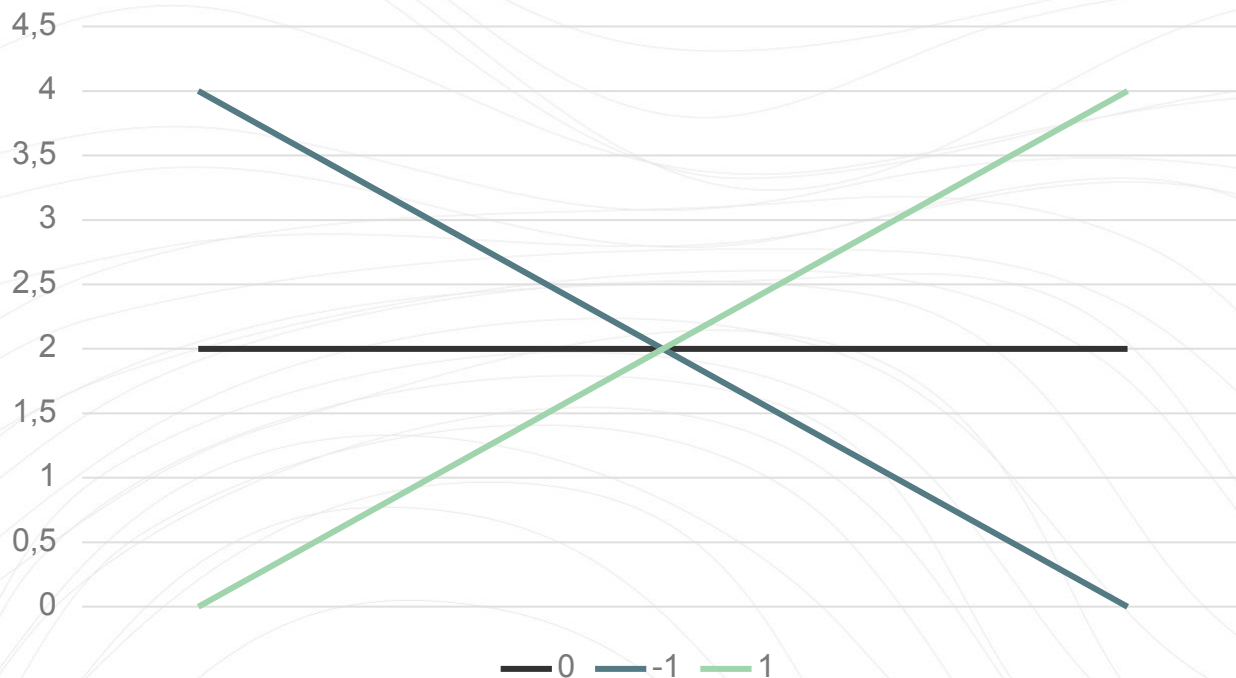
b – współczynnik ,intercept', przesunięcie

$$y = a_0 + a_1 * x_1 + b_1 + a_2 * x_2 + b_2 + \dots$$

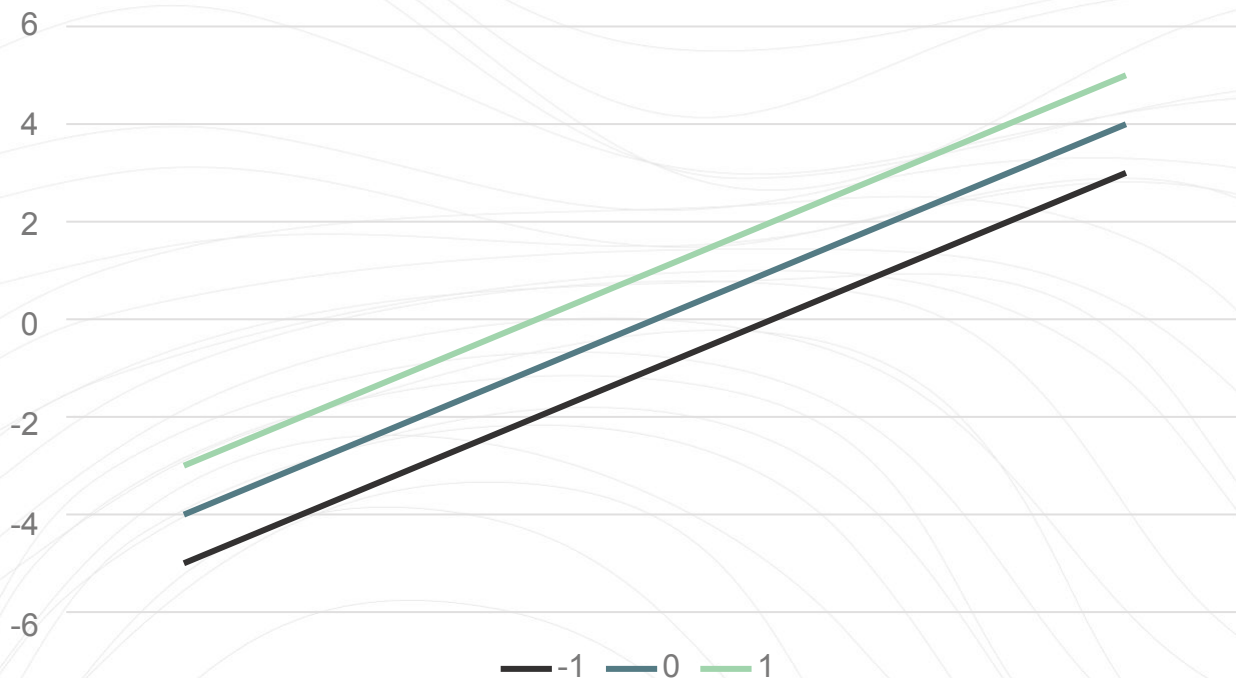
X – wejście funkcji, zmienna objaśniająca, niezależna
Y – odpowiedź funkcji, zmienna objaśniana, zależna
a – współczynnik ,slope', kierunkowy
b – współczynnik ,intercept', przesunięcie

Funkcja liniowa

Wykres funkcji liniowej zależny od współczynnika a




Wykres funkcji liniowej zależny od współczynnika b





Funkcja liniowa wielu zmiennych – hiperpłaszczyzna





Funkcja liniowa

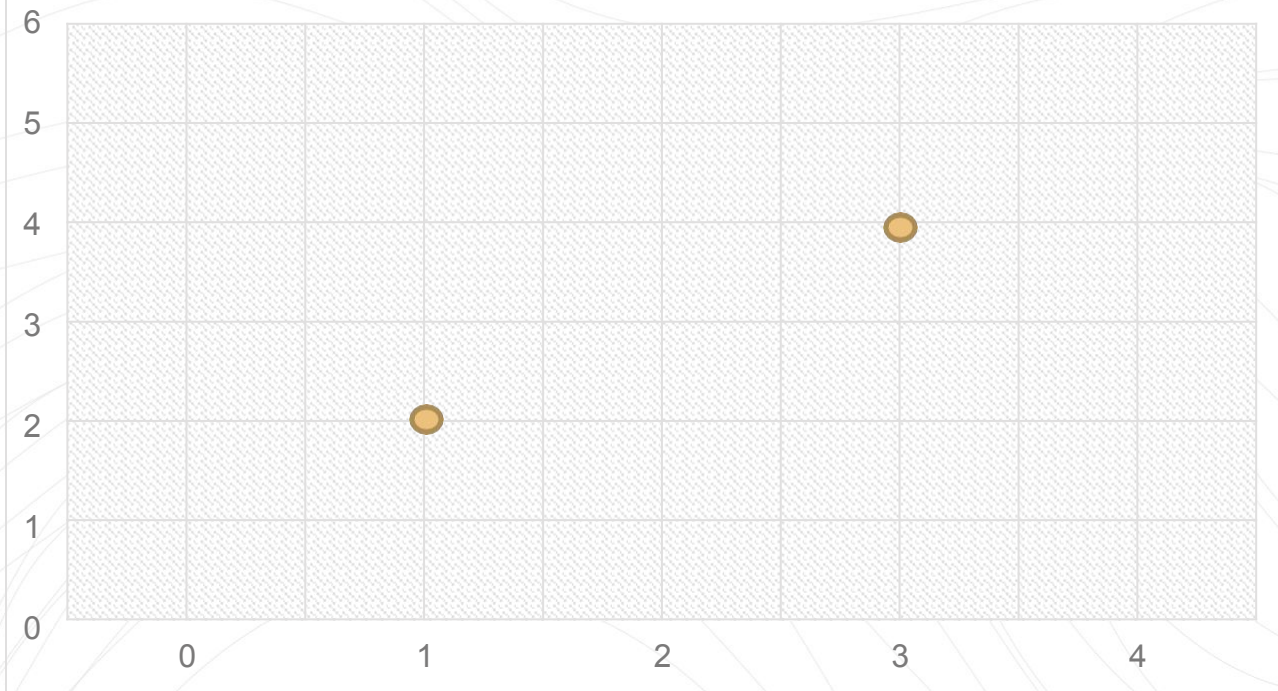
Tworzenie na podstawie dwóch punktów, A i B:

$$a = \frac{y_B - y_A}{x_B - x_A}$$


$$b = y_A - ax_A$$

x_A, x_B, y_A, y_B – wartości współrzędnych x i y punktu A i B


WYZNACZANIE FUNKCJI LINIOWEJ NA PODSTAWIE DWÓCH PUNKTÓW




WYZNACZANIE FUNKCJI LINIOWEJ NA PODSTAWIE DWÓCH PUNKTÓW




WYZNACZANIE FUNKCJI LINIOWEJ NA PODSTAWIE DWÓCH PUNKTÓW



WYZNACZANIE FUNKCJI LINIOWEJ NA PODSTAWIE DWÓCH PUNKTÓW



WYZNACZANIE FUNKCJI LINIOWEJ NA PODSTAWIE DWÓCH PUNKTÓW





Regresja liniowa (definicja)

- Przedstawia korelację dwóch zmiennych: x , y
- X nazywamy zmienną objaśniającą
- Y nazywamy zmienną objaśnianą
- Modelem jest funkcja liniowa: $y = ax + b$
- Wyznaczenie funkcji liniowej polega na minimalizacji wartości błędu określanej metodą najmniejszych kwadratów $(y - \hat{y})^2$



Regresja liniowa (implementacja)

$$a = \frac{\sum_{k=1}^n (x_i - x_{mean})(y_i - y_{mean})}{\sum_{k=1}^n (x_i - x_{mean})^2}$$
$$b = y_{mean} - ax_{mean}$$

n – ilość punktów do treningu

y_i, x_i – wartość współrzędnych kolejnych punktów

x_{mean}, y_{mean} – wartość średnia współrzędnych ze wszystkich punktów



Regresja liniowa (współczynnik determinacji)

$$R^2 = \frac{\sum_{i=1}^n (y_i^* - y_{mean})^2}{\sum_{i=1}^n (y_i - y_{mean})^2}$$

y_i^* - kolejna wartość predykcji

y_i - kolejna wartość referencyjna

y_{mean} - wartość średnia ze wszystkich referencji



Regresja liniowa (metryki – reszty)

- Wielkości odchylenia odpowiedzi modelu od danych referencyjnych
- Pokazują jak mocno na przestrzeni danych nasz model odbiega od rzeczywistości
- Jeśli wartości reszt są mniej więcej podobno dla większości punktów, oznacza to dobre zastosowanie regresji liniowej



Regresja liniowa (błąd średniokwadratowy)

- Stosowany do porównywania jakości modeli regresji
- Przedstawia średni błąd odchylenia wszystkich próbek testowanych od referencyjnych
- W treningu regresji liniowej lepiej sprawdza się r^2 , jednak jako dodatek również można go zastosować



Regresja liniowa (implementacja w sklearn)

- Pobieramy pakiet modeli liniowych:

```
from sklearn.linear_model import LinearRegression
```

- Tworzymy model regresji liniowej:

```
model = LinearRegression()
```

- Trening

```
model.fit(???)
```

- Współczynniki

```
model.intercept_, model.coef_
```

- Predykcja

```
model.predict(???)
```


- <https://www.gosc.pl/doc/759350.Rosniemy-jak-na-drozdach>
- <https://www.statystyczny.pl/regresja-liniowa/>
- Machine Learning for Developers, Rodolfo Bonnin, Birmingham-Mumbai, 2017
- https://www.naukowiec.org/wiedza/statystyka/regresja-liniowa_765.html

Dzięki!